Authorship Attribution

Progetto di Linguistica Computazionale II

Matilde Viti

A.Y. 2024/2025

Contents

Introduzione **1**

1 Preprocessing e costruzione del dataset **1**
1.1 Pulizia del testo 1
1.2 Segmentazione e costruzione del dataset 2
1.3 Undersampling 2

2 Classificazione con feature linguistiche non lessicali (Profiling-UD) **2**
2.1 Estrazione delle feature e modello 2
2.2 Valutazione 3
2.3 Feature importance per classe 4

3 Classificazione SVM con n-grammi **4**
3.1 Configurazioni 4
3.2 Valutazione delle configurazioni e modello finale 5

4 Classificazione SVM con word embeddings **5**
4.1 Estrazione delle feature e classificazione 5
4.2 Configurazioni sperimentali sul validation set 6
4.3 Risultati sul test set 6

5 Neural Language Model **7**
5.1 Andamento della training e validation loss 8
5.2 Esperimento 1: valutazione del modello al termine delle 6 epoche 9
5.3 Esperimento 2: selezione del modello migliore 9
5.4 Confronto tra i due esperimenti 9

Conclusioni **10**

Introduzione

Il presente lavoro affronta il task di *authorship attribution*, ovvero l'identificazione dell'autore di un testo sulla base delle sue caratteristiche linguistiche. Questo problema rientra nell'ambito della linguistica computazionale e del text classification, e si basa sull'ipotesi che ogni autore presenti uno stile distintivo riconoscibile attraverso specifiche proprietà del linguaggio.
L'obiettivo del lavoro è determinare l'autore dei paragrafi tratti da opere di Charlotte Brontë, George Eliot e Jane Austen, tre autrici della letteratura inglese attive tra la fine del Settecento e l'Ottocento.

Per la realizzazione di questo progetto, sono stati sviluppati diversi modelli basati su differenti rappresentazioni del testo. Il primo modello prevede l'utilizzo di un classificatore SVM lineare che impiega una rappresentazione del testo basata su informazioni linguistiche non lessicali estratte tramite il sistema Profiling-UD.
Il secondo modello, anch'esso basato su SVM lineare, rappresenta i testi attraverso n-grammi ricavati da parole, lemmi, caratteri e part-of-speech, confrontando diverse configurazioni.
Il terzo modello si basa su word embeddings pre-addestrati, combinati per ottenere una rappresentazione vettoriale di ciascun paragrafo. Su questa base viene quindi addestrato un classificatore SVM lineare, valutando l'effetto di diverse modalità di aggregazione e di diverse selezioni delle categorie grammaticali.
Infine, viene analizzato un modello neurale pre-addestrato, DistilBERT, sottoposto a fine-tuning sul task per 6 epoche; in questo caso sono stati condotti due esperimenti: nel primo il modello viene valutato al termine dell'addestramento, mentre nel secondo viene selezionato il checkpoint migliore sulla base delle prestazioni sul validation set. In questo modo è possibile confrontare due diverse modalità di valutazione del modello neurale e verificarne il contributo rispetto ai metodi precedenti.

1. Preprocessing e costruzione del dataset

La fase di preprocessing ha l'obiettivo di trasformare i testi grezzi provenienti da Project Gutenberg in un dataset strutturato e pulito. I testi originali presentano infatti numerosi elementi di rumore (metadata, note editoriali, indici, illustrazioni) che non sono rilevanti dal punto di vista linguistico e che potrebbero introdurre bias nel modello.

1.1 Pulizia del testo

La pulizia è stata effettuata tramite la funzione `clean_gutenberg`, che implementa una pipeline di normalizzazione e filtraggio articolata. In primo luogo, vengono rimossi automaticamente gli header standard di Project Gutenberg, mentre la parte finale del testo viene identificata combinando il riconoscimento di marker narrativi ed editoriali (con parole chiave come "publisher", "printed by", "copyright", ecc) tenendo però in considerazione, qualora questi elementi non fossero presenti, il marker standard di chiusura del corpus Gutenberg.
L'inizio della narrazione non viene identificato tramite un semplice taglio iniziale, ma attraverso una procedura euristica. La funzione cerca innanzitutto eventuali sezioni come "Contents" o "Table of contents", quindi individua un possibile heading di apertura e verifica che non si tratti ancora dell'indice, analizzando le righe successive e contando quante di esse corrispondono a

intestazioni tipiche (come “Chapter”, “Book”, “Volume” o “Part”): una concentrazione elevata di tali elementi viene interpretata come indicativa della presenza di un indice.

La funzione procede poi con la rimozione di contenuti non narrativi, tra cui blocchi di illustrazione, note a piè di pagina, riferimenti numerici e marcatori tipografici, come ad esempio il corsivo con underscore. Infine, vengono effettuati ulteriori interventi di pulizia e normalizzazione, come la standardizzazione dei trattini, la rimozione di alcuni artefatti tipografici residui e la regolarizzazione degli spazi.

1.2 Segmentazione e costruzione del dataset

I testi puliti vengono suddivisi in paragrafi utilizzando le righe vuote come delimitatori. Ogni paragrafo viene successivamente normalizzato e filtrato in base alla lunghezza, mantenendo solo quelli compresi tra 50 e 100 token.
I paragrafi ottenuti vengono organizzati in tre split (train, validation e test) a livello di libro, evitando che porzioni dello stesso testo compaiano in più split.

1.3 Undersampling

È stato applicato un undersampling poiché la distribuzione dei paragrafi tra gli autori risultava fortemente sbilanciata, in particolare nei set di validation e test. Ad esempio, nel validation set George Eliot era rappresentata da soli 216 paragrafi, mentre Charlotte Brontë ne aveva 705, e nel test set si osservava uno squilibrio opposto (George Eliot: 641 vs Charlotte Brontë: 194). Perciò, è stata fissata una soglia massima di 200 istanze per autore nei set di validation e test, lasciando invariato il test set di Charlotte Brontë, pari a 194 istanze.

Autore	**Train**	**Validation**	**Test**
Charlotte Brontë	1436	200	194
George Eliot	1783	200	200
Jane Austen	1093	200	200
Totale	4312	600	594

Table 1.1: Distribuzione delle istanze per classe nei diversi split del dataset dopo l’undersampling

2. Classificazione con feature linguistiche non lessicali (Profiling-UD)

Il primo classificatore si basa su caratteristiche linguistiche non lessicali, estratte con il sistema Profiling-UD. In questo approccio, i paragrafi preprocessati non vengono descritti in base al loro contenuto lessicale, ma attraverso un insieme di feature che catturano proprietà formali del testo.

2.1 Estrazione delle feature e modello

I paragrafi preprocessati vengono inizialmente convertiti in un formato compatibile con Profiling-UD. Ogni paragrafo viene salvato come file `.txt` indipendente, mentre le informazioni relative

ad autore, libro e split vengono memorizzate in un file JSON (`paragraph_info.json`). Questo consente di mantenere una corrispondenza tra i documenti originali e le feature estratte.
A partire da questi file, Profiling-UD analizza ciascun paragrafo e produce un vettore numerico di feature linguistiche. Le feature ottenute vengono quindi ricaricate e associate ai rispettivi paragrafi, così da costruire un dataset in cui ogni istanza è descritta da un vettore numerico e dalla relativa etichetta, ovvero l'autore.

Sulla base delle informazioni assegnate in precedenza, il dataset viene poi suddiviso nei tre split di training, validation e test. Per la classificazione, viene utilizzata una Support Vector Machine lineare implementata tramite `LinearSVC`, con i seguenti parametri: `C=1.0`, `class_weight="balanced"`, `dual=False` e `max_iter=10000`.

2.2 Valutazione

Per valutare il modello sono state considerate diverse strategie. In primo luogo, è stata utilizzata una 5-fold cross-validation sul training set.
Dopodiché, il modello è stato addestrato sull'intero training set e valutato separatamente su validation e test set.

Modello / Set	**Accuracy**	**F1-macro**
Cross-validation (5-fold)	0.64	0.63
Validation	0.69	0.69
Test	0.68	0.68
Dummy Classifier	0.32	0.32

Table 2.1: Confronto delle prestazioni del modello nei diversi set di valutazione e rispetto alla baseline

I risultati mostrano che le prestazioni su validation e test set sono molto simili, in particolare, il test set presenta valori di accuracy e macro F1 comparabili a quelli del validation set, suggerendo che il modello non soffre di overfitting significativo. Le prestazioni ottenute tramite cross-validation, invece, risultano leggermente inferiori.

Come termine di confronto, è stato implementato un `Dummy Classifier` con strategia *uniform*, che assegna le classi in modo casuale. Questo modello ottiene accuracy e Macro F1-score pari a circa 0.32, valore vicino a quanto ci si aspetterebbe da una scelta casuale in un problema a tre classi (circa 1/3). Il confronto mette bene in evidenza che il modello basato sulle feature linguistiche riesce a catturare informazioni utili a distinguere tra le tre autrici.

Considerando tutte le valutazioni, il test set rappresenta la misura più affidabile delle prestazioni del modello, in quanto comprende dati mai visti durante l'addestramento. I risultati ottenuti su questo set confermano l'efficacia del modello, mostrando un netto miglioramento rispetto alla baseline.

2.3 Feature importance per classe

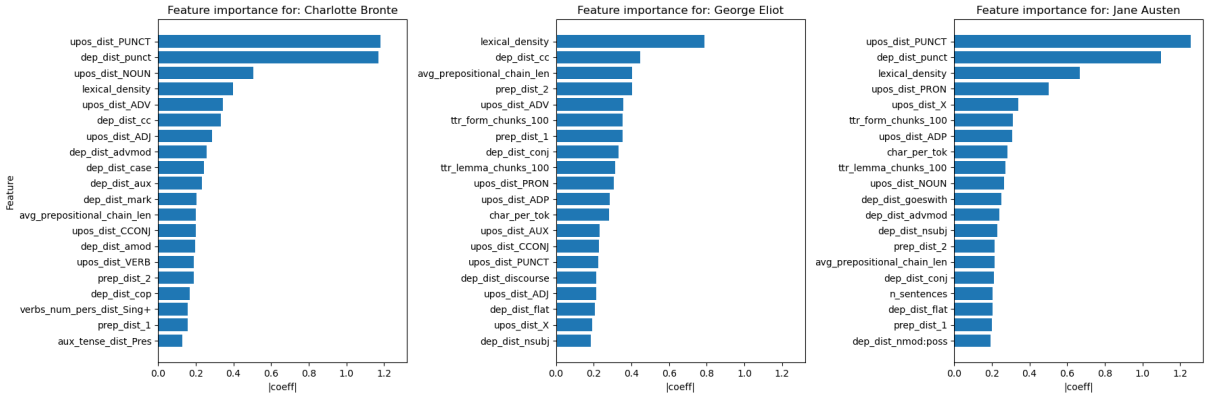

FIGURE 2.1: Top 20 feature più rilevanti per ciascun autore, ordinate per valore assoluto del coefficiente della SVM lineare

La figura 2.1 mostra che, per Charlotte Brontë e Jane Austen, le feature più rilevanti sono soprattutto quelle legate alla punteggiatura, in particolare `upos_dist_PUNCT` e `dep_dist_punct`: la prima misura la proporzione di segni di punteggiatura nel testo, mentre la seconda considera la loro distribuzione all'interno della struttura sintattica. Per George Eliot, invece, la feature dominante è `lexical_density`, la quale indica la presenza di testo ricco di contenuto dato da parole "piene", seguita da indicatori legati alla coordinazione e alla complessità sintattica, come `dep_dist_cc` e `avg_prepositional_chain_len`, che rispettivamente tengono conto dell'uso di congiunzioni coordinanti e della lunghezza media delle sequenze di sintagmi preposizionali.

Per quanto riguarda la feature `lexical_density`, la quale risulta rilevante per tutte e tre le autrici, presenta un coefficiente con segno diverso. Difatti, è associata positivamente a George Eliot, mentre presenta coefficienti negativi per Charlotte Brontë e Jane Austen. Ciò suggerisce che una maggiore densità lessicale contribuisce a identificare i testi di George Eliot, mentre tende a distinguere, in senso opposto, quelli delle altre due autrici.

3. Classificazione SVM con n-grammi

In questo task è stato implementato un classificatore basato su `LinearSVC` utilizzando una rappresentazione del testo fondata su n-grammi estratti da diverse informazioni linguistiche: parole, lemmi, POS e caratteri, ricavate dai file `.conllu` prodotti nel Task 1. Le informazioni relative ad autore e split sono state recuperate dal file JSON dei metadati, successivamente integrate nella struttura dei documenti.

3.1 Configurazioni

Sono state definite tre diverse configurazioni della rappresentazione testuale, variando la lunghezza degli n-grammi per ciascun tipo di informazione linguistica (POS, lemma, parole e caratteri).

Le configurazioni utilizzate sono le seguenti:

- **Configurazione 1**: bigrammi di POS e parole, trigrammi di lemmi e caratteri
- **Configurazione 2**: trigrammi di POS e parole, bigrammi di lemmi e caratteri

- **Configurazione 3**: bigrammi di POS e lemmi, unigrammi di parole e trigrammi di caratteri

Per ciascuna configurazione, le feature vengono estratte tramite la funzione `extract_all_ngrams`, che genera un dizionario di feature per ogni documento. Successivamente, il dataset viene suddiviso in training, validation e test set utilizzando la funzione `split_dataset`.

Inoltre, per ridurre la dimensionalità dello spazio delle feature e limitare il rumore, è stato applicato un filtraggio che rimuove le feature presenti in meno di 5 documenti del training set.

Le feature vengono poi vettorizzate tramite `DictVectorizer` e normalizzate con `MaxAbsScaler`. Il classificatore utilizzato è `LinearSVC` (`C=1.0`, `class_weight = "balanced"`, `dual = False`, `max_iter = 10000`).

3.2 Valutazione delle configurazioni e modello finale

Le tre configurazioni hanno ottenuto sul validation set risultati pressoché identici, con accuracy e macro F1 pari a 0.86. Le differenze tra i modelli riguardano soprattutto la distribuzione delle prestazioni tra le singole classi.
In assenza di uno scarto netto nelle metriche complessive, la **Configurazione 2** risulta leggermente più equilibrata tra le classi (Tabella 3.1, sezione *Validation*) e viene quindi selezionata come modello finale, in quanto presenta un miglior equilibrio tra precision e recall sulle diverse classi.

	Validation			**Test**		
Classe	Precision	Recall	F1	Precision	Recall	F1
Charlotte Brontë	0.83	0.88	0.85	0.82	0.85	0.83
George Eliot	0.83	0.94	0.88	0.78	0.91	0.84
Jane Austen	0.96	0.79	0.87	0.92	0.73	0.82
Accuracy			**0.86**			**0.83**
Macro avg	0.87	0.87	0.86	0.84	0.83	0.83
Weighted avg	0.87	0.86	0.86	0.84	0.83	0.83

Table 3.1: Risultati della configurazione selezionata (trigrammi di POS e word, bigrammi di lemma e char) su validation e test set

Il modello selezionato è stato quindi valutato sul test set, ottenendo un'accuracy e Macro F1 pari a 0.83. Come mostrato in Tabella 3.1 (sezione *Test*), le prestazioni risultano leggermente inferiori rispetto al validation set, ma mantengono un comportamento coerente tra le classi: *George Eliot* continua a essere la classe più facilmente riconoscibile, mentre *Jane Austen* rimane la più difficile da classificare.

4. Classificazione SVM con word embeddings

4.1 Estrazione delle feature e classificazione

In questo task è stato implementato un classificatore SVM lineare basato su una rappresentazione vettoriale dei documenti ottenuta tramite aggregazione di word embeddings pre-addestrati (UKWAC, 128 dimensioni). L'obiettivo è confrontare diverse modalità di rappresentazione del testo, variando sia il metodo di aggregazione degli embeddings sia le categorie morfosintattiche (`POS`) considerate.

La pipeline prevede il caricamento dei documenti dai file `.conllu`, da cui vengono ricavati i token normalizzati e le rispettive POS. Per ogni configurazione, le parole selezionate in base alle POS vengono trasformate in un vettore tramite aggregazione dei relativi embeddings.

Sono stati confrontati tre metodi di aggregazione (*mean*, *sum* e *max*) sul validation set per individuare la configurazione più efficace, successivamente valutata sul test set per analizzarne la capacità di generalizzazione.

Il classificatore utilizzato è `LinearSVC`, inserito in una `Pipeline` con `StandardScaler`. I parametri sono stati mantenuti costanti in tutte le configurazioni: `C = 1.0`, `class_weight = None`, `dual = False`, `max_iter = 10000`, `random_state = 42`.

4.2 Configurazioni sperimentali sul validation set

Sono state testate sei configurazioni, variando sia l'insieme di POS considerate sia il metodo di aggregazione degli embeddings. La Tabella 4.1 riporta i risultati ottenuti sul validation set.

Table 4.1: Risultati sul validation set (configurazioni migliori in grassetto).

Config.	POS	Agg.	CB F1	GE F1	JA F1	Acc.
conf_1	**NOUN, ADJ, VERB**	**mean**	**0.72**	**0.71**	**0.76**	**0.73**
conf_1a	VERB, NOUN, INTJ, DET	mean	0.69	0.72	0.73	0.71
conf_2	**NOUN, ADJ, VERB**	**sum**	**0.72**	**0.71**	**0.76**	**0.73**
conf_2a	VERB, NOUN, INTJ, DET	sum	0.69	0.72	0.72	0.71
conf_3	NOUN, ADJ, VERB	max	0.61	0.64	0.63	0.62
conf_3a	VERB, NOUN, INTJ, DET	max	0.60	0.63	0.62	0.62

CB = Charlotte Brontë, GE = George Eliot, JA = Jane Austen.

Le configurazioni migliori sul validation set sono `conf_1` e `conf_2`, entrambe basate sulle POS `NOUN`, `ADJ` e `VERB`, le quali ottengono la stessa accuracy (0.73) e valori di F1 molto simili per tutte le classi. Questo risultato suggerisce che nomi, aggettivi e verbi riflettano più direttamente alcune regolarità dello stile autoriale rispetto a POS meno rilevanti sul piano stilistico, come `INTJ` e `DET`, che non sembrano apportare benefici evidenti. L'aggregazione *max*, al contrario, produce prestazioni nettamente inferiori rispetto a *mean* e *sum*.

4.3 Risultati sul test set

Poiché `conf_1` e `conf_2` hanno ottenuto risultati equivalenti sul validation set, entrambe le configurazioni sono state valutate sul test set per analizzarne il comportamento su dati non visti. Pur non rappresentando la procedura standard di selezione del modello, questa scelta è stata adottata per chiarire il comportamento di due configurazioni che il validation set non permetteva di distinguere in modo netto.

Table 4.2: Risultati sul test set per `conf_1`.

Classe	Precision	Recall	F1-score	Support
Charlotte Brontë	0.60	0.56	0.58	194
George Eliot	0.55	0.72	0.63	200
Jane Austen	0.70	0.52	0.59	200
Accuracy			0.60	594
Macro avg	0.61	0.60	0.60	594
Weighted avg	0.61	0.60	0.60	594

Table 4.3: Risultati sul test set per `conf_2`.

Classe	**Precision**	**Recall**	**F1-score**	**Support**
Charlotte Brontë	0.62	0.57	0.60	194
George Eliot	0.57	0.76	0.65	200
Jane Austen	0.71	0.53	0.61	200
Accuracy			0.62	594
Macro avg	0.63	0.62	0.62	594
Weighted avg	0.63	0.62	0.62	594

I risultati mostrano un leggero vantaggio della configurazione `conf_2` *(sum)*, che ottiene un'accuracy e una Macro-F1 pari a 0.62, mentre la configurazione `conf_1` *(mean)*, si ferma a 0.60 per entrambe le misure.

Osservando i risultati per classe, George Eliot è quella che presenta le prestazioni migliori in entrambe le configurazioni, con i valori più elevati di recall (0.72 in *conf_1* e 0.76 in *conf_2*) e di F1-score (0.63 in *conf_1* e 0.65 in *conf_2*). Charlotte Brontë e Jane Austen mostrano invece valori inferiori, in particolare per la recall, indicando una maggiore difficoltà del modello nel riconoscere correttamente i loro testi.

5. Neural Language Model

Il task finale del progetto si basa sul modello pre-addestrato *DistilBERT-base-cased*, una versione più leggera e veloce del modello BERT, progettata per mantenere buone prestazioni riducendo al contempo il numero di parametri.

I dati utilizzati in questo task derivano dalla fase di preprocessing già descritta nei task precedenti, in cui i file testuali e i relativi metadati sono stati combinati per costruire i dataset di training, validation e test. Le etichette sono state quindi codificate in forma numerica. Successivamente, i dati sono stati tokenizzati tramite *DistilBERT* e, infine, i dataset sono stati convertiti nel formato *torch* per garantire la corretta gestione delle label come valori interi durante il training del modello. L'addestramento è stato eseguito su Google Colab, sfruttando una *GPU NVIDIA T4* per accelerare il processo di training.

Sono stati condotti due esperimenti principali: nel primo caso il modello viene valutato al termine delle 6 epoche di fine-tuning, mentre nel secondo viene selezionato automaticamente il checkpoint migliore sulla base delle prestazioni sul validation set, utilizzando la metrica weighted F1 come criterio di selezione.

5.1 Andamento della training e validation loss

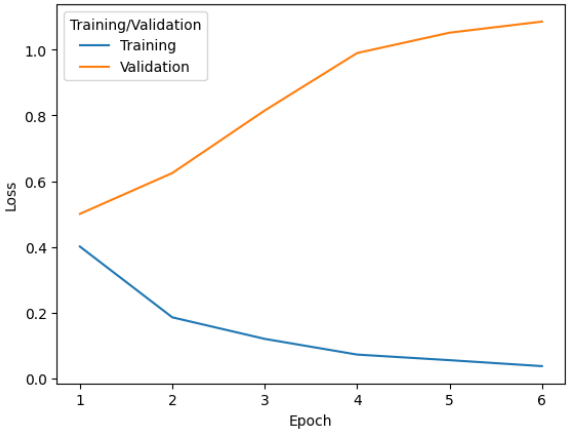

(A) Esperimento 1

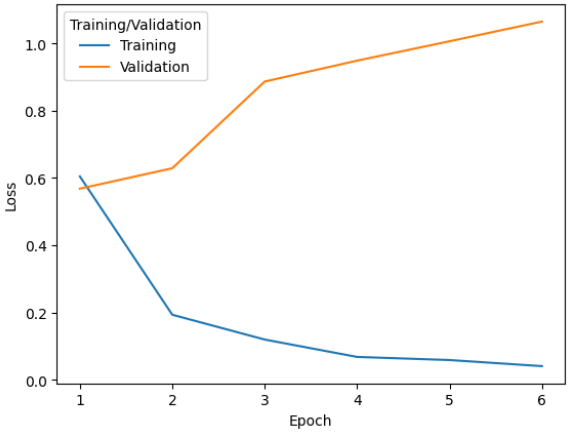

(B) Esperimento 2

FIGURE 5.1: Andamento della training e validation loss nei due esperimenti (lineplot); la curva di training è mostrata in blu, quella di validation in arancione.

Le curve di loss dei due esperimenti (Figure 5.1) mostrano un andamento molto simile: la training loss diminuisce progressivamente, mentre la validation loss aumenta già dalle prime epoche. Questo comportamento evidenzia un chiaro fenomeno di overfitting, con il modello che apprende sempre meglio i dati di training ma perde capacità di generalizzazione.

Epoca	**Training Loss**	**Validation Loss**	**F1**
1	0.400954	0.500370	0.813501
2	0.185415	0.624634	0.836038
3	0.119852	0.815001	0.807000
4	0.072038	0.989928	0.810909
5	0.055010	1.051909	0.803330
6	0.036844	1.085715	0.797973

TABLE 5.1: Andamento di loss e F1 sul validation set (Esperimento 1)

Epoca	**Training Loss**	**Validation Loss**	**F1**
1	0.604732	0.568392	0.794691
2	0.193376	0.629077	0.831115
3	0.119583	0.887047	0.803742
4	0.067880	0.949167	0.824958
5	0.058663	1.006840	0.823238
6	0.040508	1.065395	0.817433

TABLE 5.2: Andamento di loss e F1 sul validation set (Esperimento 2)

I valori di F1 sul validation set confermano l'andamento osservato: in entrambi gli esperimenti il massimo si registra alla seconda epoca, seguito da un peggioramento nelle epoche successive. Ciò indica che il modello raggiunge le migliori prestazioni nelle fasi iniziali del training, prima che gli effetti dell'overfitting diventino più evidenti, rendendo la seconda epoca il punto ottimale di generalizzazione.

5.2 Esperimento 1: valutazione del modello al termine delle 6 epoche

Nel primo esperimento il modello *DistilBERT-base-cased* è stato fine-tuned per 6 epoche sul training set, utilizzando una batch size pari a 8 e un learning rate di *5e-6*. Al termine delle 6 epoche di addestramento, la valutazione sul test set è stata effettuata utilizzando il modello finale.

Classe	**Precision**	**Recall**	**F1-score**	**Support**
Charlotte Brontë	0.85	0.77	0.81	194
George Eliot	0.78	0.92	0.84	200
Jane Austen	0.89	0.82	0.85	200
Accuracy			0.84	594
Macro avg	0.84	0.83	0.83	594
Weighted avg	0.84	0.84	0.83	594

Table 5.3: Classification report sul test set - Esperimento 1

I risultati mostrano prestazioni complessivamente buone e bilanciate tra le tre classi. Tuttavia, si può osservare una certa variabilità tra precision e recall: George Eliot presenta un recall elevato, mentre Jane Austen mostra una precision più alta. Charlotte Brontë risulta leggermente più difficile da classificare, con valori più contenuti ma equilibrati. Nonostante l'overfitting osservato, il modello dell'ultima epoca mantiene una buona capacità predittiva sul test set.

5.3 Esperimento 2: selezione del modello migliore

Nel secondo esperimento viene adottata una selezione automatica del modello basata sulle prestazioni sul validation set, adottando la metrica weighted F1 come criterio. Sebbene il modello sia stato addestrato per 6 epoche, il checkpoint migliore corrisponde alla seconda epoca, in linea con quanto osservato nell'analisi della loss.

Classe	**Precision**	**Recall**	**F1-score**	**Support**
Charlotte Brontë	0.91	0.65	0.76	194
George Eliot	0.85	0.90	0.88	200
Jane Austen	0.76	0.93	0.84	200
Accuracy			0.83	594
Macro avg	0.84	0.83	0.82	594
Weighted avg	0.84	0.83	0.82	594

Table 5.4: Classification report sul test set - Esperimento 2

I risultati sul test set mostrano prestazioni buone, ma leggermente inferiori rispetto al modello dell'ultima epoca, con maggiore variabilità tra precision e recall. Charlotte Brontë presenta alta precision e basso recall, Jane Austen il comportamento opposto, mentre George Eliot risulta più equilibrata.

5.4 Confronto tra i due esperimenti

Il confronto tra i due approcci mostra che il modello valutato all'ultima epoca ottiene prestazioni leggermente superiori e più bilanciate tra le classi rispetto al modello selezionato sul validation set. La selezione basata sulla metrica weighted F1 permette comunque di individuare un punto

di arresto coerente con l'andamento della loss e di limitare l'overfitting, ma in questo caso non porta a un miglioramento sul test set.

Conclusioni

In questo lavoro è stato affrontato il task di *authorship attribution* confrontando diverse modalità di rappresentazione del testo e relativi modelli di classificazione.

I risultati mostrano chiaramente come le prestazioni dipendano dal tipo di rappresentazione utilizzata. Il modello neurale basato su DistilBERT, nello specifico il primo esperimento, ottiene i risultati migliori sul test set (accuracy 0.84, macro F1 0.83), ma il vantaggio rispetto al modello SVM con n-grammi è molto ridotto, visto che anche quest'ultimo raggiunge 0.83 sia in accuracy sia in macro F1. Questo suggerisce che, in questo tipo di task, rappresentazioni più semplici ma capaci di catturare pattern locali, come gli n-grammi, possono risultare molto competitive.

Al contrario, il modello basato su word embeddings è quello che mostra le prestazioni più basse. Questo risultato è coerente con il tipo di rappresentazione adottata: l'aggregazione degli embeddings in un unico vettore porta infatti a perdere informazioni importanti come l'ordine delle parole e la struttura del testo, che risultano invece centrali per distinguere lo stile degli autori.

Le feature linguistiche non lessicali, infine, mostrano comunque prestazioni nettamente superiori alla baseline casuale. Questo indica che anche aspetti morfosintattici e strutturali contengono informazioni utili per il riconoscimento dell'autore, sebbene non siano sufficienti da soli a raggiungere i risultati migliori.

Per concludere, il confronto tra i diversi modelli evidenzia che, nel task di *authorship attribution*, non conta solo la complessità del modello, ma soprattutto il modo in cui il testo viene rappresentato. I risultati mostrano infatti che anche approcci più semplici possono restare molto efficaci, se riescono a catturare i tratti stilistici davvero rilevanti.